PROYECTO DE INTELIGENCIA ARTIFICIAL

INTEGRANTES
DHARLA JOSE DURAN RIOBO
CESAR ANDRÉS AMAYA DÍAZ
OSCAR ANDRÉS HUNDELSHAUSSEN BARRETO

MATERIA
INTELIGENCIA ARTIFICIAL

DOCENTE
TONNY JIMENEZ MARQUEZ

TEMA
SISTEMA DE ALERTA TEMPRANA DE RIESGO MATERNO-PERINATAL EN ZONAS DISPERSAS Y COMUNIDADES INDÍGENAS

GRUPO

02

UNIVERSIDAD POPULAR DEL CESAR
VALLEDUPAR – CESAR
COLOMBIA
2026

Tabla de contenido

I. INTRODUCCIÓN 3
II. TITULO Y EQUIPO 4
III. PLANTEAMIENTO Y FORMULACIÓN DEL PROBLEMA 5
IV. JUSTIFICACIÓN 6
V. OBJETIVO GENERAL 7
VI. OBJETIVOS ESPECÍFICOS 7
VII. TIPO DE PROBLEMA DE IA 7
VIII. ESTADO DEL ARTE 7
1) REFERENCIAS INTERNACIONALES 7
2) REFERENCIA NACIONAL 8
3) REFERENCIA REGIONAL 8
IX. FUENTE(S) DE DATOS IDENTIFICADAS 9
X. METODOLOGÍA PROPUESTA ..... **¡Error! Marcador no definido.**
Fase 1. Definición y Propuesta ..... **¡Error! Marcador no definido.**
Fase 2. Obtención de Datos ..... **¡Error! Marcador no definido.**
Fase 3. Integración y Análisis Exploratorio (EDA) ..... **¡Error! Marcador no definido.**
Fase 4. Preparación de Datos ..... **¡Error! Marcador no definido.**
Fase 5. Construcción de Modelos ..... **¡Error! Marcador no definido.**
Fase 6. Evaluación e Interpretación ..... **¡Error! Marcador no definido.**
Fase 7. Visualización en Python y Tablero Analítico ... **¡Error! Marcador no definido.**
Tabla 2. Cronograma de actividades ..... **¡Error! Marcador no definido.**
Fase 8. Resultados Esperados ..... **¡Error! Marcador no definido.**
XI. CONCLUSIÓN 18
XII. BIBLIOGRAFÍA 18

I. INTRODUCCIÓN

La atención de la salud materno-perinatal en Colombia enfrenta brechas asociadas a la dispersión geográfica, la disponibilidad de servicios especializados y las barreras socioculturales. En La Guajira y Cesar, estas condiciones dificultan el seguimiento prenatal oportuno de gestantes residentes en zonas rurales e indígenas. La propuesta inicial plantea explorar un sistema de alerta temprana con funcionamiento local y sincronización posterior, destinado a apoyar a los agentes comunitarios de salud.

La Fase 1 formuló el problema y caracterizó dos fuentes complementarias: las Estadísticas Vitales del DANE de 2024 como contexto epidemiológico y un conjunto clínico simulado de 1.508 registros de controles prenatales. Para la Fase 2 se desarrollaron experimentos de aprendizaje supervisado utilizando variables fisiológicas, logísticas y sociodemográficas, con el propósito de estudiar su capacidad para clasificar el riesgo y distinguir desenlaces gestacionales desfavorables.

El presente informe constituye el avance técnico solicitado para la segunda fase del proyecto de aula de Inteligencia Artificial. Describe el diagnóstico de calidad de datos, las transformaciones, la partición de entrenamiento/validación/prueba, la implementación de modelos de referencia (Regresión Logística y SVM) y el uso de redes neuronales multicapa (MLP). Asimismo, expone ajustes, métricas, matrices de confusión, análisis de umbrales y diferencias descriptivas entre etnias y territorios.

El estudio mantiene una delimitación necesaria: los 1.508 registros de entrenamiento son sintéticos. Las métricas son válidas como resultados del experimento reportado, pero no acreditan capacidad diagnóstica, utilidad clínica ni seguridad de implementación en pacientes reales. El motor de reglas obstétricas y el funcionamiento móvil sin conexión, concebidos en la propuesta, corresponden al desarrollo futuro y no se presentan como componentes clínicamente verificados en esta fase.

II. TITULO Y EQUIPO

Fecha: (DD/MM/AAAA)	24/09/2026		
Título del proyecto:	Sistema de Alerta Temprana de Riesgo Materno-Perinatal en Zonas Dispersas y Comunidades Indígenas Mediante Inteligencia Artificial		
INTEGRANTES			
Nombre del estudiante 1:	Dharla Jose Duran Riobo		
Correo electrónico:	Dharlajduran@unicesar.edu.co	Teléfono/celular	3216805285
Nombre del estudiante 2:	Cesar Andrés Amaya Díaz		
Correo electrónico:	cesaraamaya@unicesar.edu.co	Teléfono/celular	322 5576477
Nombre del estudiante 3:	Oscar Andrés Hundelshaussen Barreto		
Correo electrónico:	ohundelshaussen@unicesar.edu.co	Teléfono/celular	320 6821198

III. PLANTEAMIENTO Y FORMULACIÓN DEL PROBLEMA

La mortalidad materna y perinatal representó históricamente un desafío crítico de salud pública caracterizado por una severa inequidad territorial en Colombia. En los departamentos de La Guajira y el Cesar, la presencia de amplias zonas de geografía accidentada dificultó el acceso continuo a los servicios médicos de atención prenatal. Las estadísticas vitales publicadas por el DANE para el año 2024 evidenciaron una cifra nacional de 453,901 nacimientos frente a 21,250 defunciones fetales y 275,778 no fetales. A pesar de constituir un porcentaje minoritario en valores absolutos, la ocurrencia de fatalidades afectó de forma desproporcionada a las comunidades indígenas vulnerables. La población Wayúu registró tasas de mortalidad materna significativamente superiores a la media nacional debido al aislamiento geográfico e inexistencia de infraestructura hospitalaria.

El problema central radicó en la imposibilidad de detectar oportunamente los signos de alarma fisiológicos durante la gestación en asentamientos rurales dispersos. Las gestantes residentes en zonas apartadas debieron recorrer distancias superiores a los 150 kilómetros para acceder a un centro hospitalario básico. Esta barrera logística provocó que complicaciones graves como preeclampsia, eclampsia, hemorragias obstétricas y diabetes gestacional progresaran sin diagnóstico temprano. Asimismo, la falta de transporte medicalizado y las demoras en las remisiones de urgencia incrementaron drásticamente la probabilidad de desenlaces fatales. La ausencia de seguimiento clínico continuo impidió a los promotores de salud reaccionar con efectividad antes del parto.

Adicionalmente, las barreras socioculturales y lingüísticas profundizaron la desatención institucional en las comunidades indígenas arhuacas, wiwas y wayúu de la región. Muchas mujeres gestantes prefirieron acudir exclusivamente a la medicina tradicional por desconfianza hacia el sistema de salud occidental descontextualizado. La falta de herramientas tecnológicas adaptadas al territorio impidió la articulación entre el saber ancestral de las parteras y los protocolos médicos oficiales. Esta desconexión epidemiológica generó un subregistro sistemático de patologías de alto riesgo en las planillas de control prenatal. Por consiguiente, la falta de monitoreo en el punto de atención perpetuó una brecha histórica de mortalidad evitable.

Por otro lado, la brecha de conectividad digital en la Alta Guajira y la Serranía del Perijá inhabilitó el uso de plataformas convencionales. Los sistemas de información de las Entidades Promotoras de Salud requirieron conexión constante a internet, condición inexistente en los puestos de salud rurales. Los agentes comunitarios recolectaron datos clínicos en formularios de papel con alta probabilidad de pérdida, alteración o demora en la digitalización. Esta latencia en el flujo de información causó que las alertas de riesgo alto llegaran a los hospitales cuando la emergencia obstétrica resultaba irreversible. La carencia de un sistema de procesamiento local en dispositivos móviles consolidó una falla estructural en la vigilancia epidemiológica.

IV. JUSTIFICACIÓN

La ejecución de este proyecto se justificó en la necesidad imperiosa de transformar el modelo reactivo de vigilancia epidemiológica hacia un esquema preventivo e itinerante. Los sistemas tradicionales de salud operaron desde una perspectiva centralizada e ineficaz para la dinámica de la ruralidad dispersa. La implementación de un mecanismo tecnológico capaz de funcionar sin señal de internet permitió descentralizar el diagnóstico de riesgo obstétrico. Al trasladar la capacidad de evaluación hacia las zonas rurales mediante promotores comunitarios, se garantizó una identificación temprana de patologías letales. Esta intervención oportuna facilitó la programación de traslados preventivos, reduciendo la incidencia de emergencias críticas y muertes evitables.

Desde una perspectiva técnica, la integración de modelos de inteligencia artificial resolvió la complejidad de evaluar múltiples factores de riesgo interconectados. La combinación de datos epidemiológicos macro del DANE con un dataset clínico de 1,508 registros rurales brindó una base de entrenamiento sólida. Los algoritmos de Regresión Logística y Máquinas de Vectores de Soporte evaluaron patrones no lineales entre variables biológicas y determinantes sociales. El análisis simultáneo de la presión arterial, el índice de masa corporal, las semanas de gestación y la distancia al hospital generó una categorización precisa. Esta capacidad analítica superó las limitaciones de los métodos manuales de evaluación clínica tradicional.

El enfoque diferencial e intercultural representó el pilar fundamental para garantizar la viabilidad y apropiación social de la solución propuesta. El sistema incorporó variables sociodemográficas y étnicas dentro del cálculo predictivo de riesgo para reconocer las vulnerabilidades de cada territorio. La herramienta ofreció una interfaz intuitiva apta para el personal auxiliar y las parteras tradicionales en el campo. Al respetar las dinámicas comunitarias, el proyecto promovió una articulación armónica entre la medicina ancestral y la tecnología médica avanzada. Esta sinergia permitió dignificar la atención en salud de las mujeres indígenas, reduciendo la brecha de inequidad social.

Finalmente, la viabilidad tecnológica del desarrollo bajo arquitecturas móviles ligeras como Flutter o React Native aseguró su sostenibilidad operativa en el tiempo. El almacenamiento de datos en bases locales mediante SQLite garantizó la continuidad del servicio en áreas desconectadas. La sincronización automatizada posterior hacia servidores centrales permitió actualizar las historias clínicas en cuanto el dispositivo detectó señal móvil. Este avance fortaleció la toma de decisiones institucionales y la asignación eficiente de recursos de transporte medicalizado en La Guajira y el Cesar. De este modo, la propuesta demostró un impacto directo en la salvaguarda de la vida materno-perinatal en la región.

V. OBJETIVO GENERAL

Desarrollar un Sistema de Alerta Temprana basado en modelos de aprendizaje automático y reglas clínicas integrados en una aplicación móvil ligera con capacidad de reporte offline, destinado a la clasificación y predicción oportuna del riesgo materno-perinatal en zonas dispersas y comunidades indígenas de La Guajira y el Cesar.

VI. OBJETIVOS ESPECÍFICOS

1. Consolidar la arquitectura de datos mediante la integración de las Estadísticas Vitales del DANE (2024) y un dataset clínico simulado de 1,508 registros de controles prenatales rurales, aplicando técnicas de imputación para datos faltantes e incongruencias de captura.
2. Entrenar y evaluar modelos de clasificación supervisada como Regresión Logística y Máquinas de Vectores de Soporte (SVM), aplicando técnicas de balanceo sintético de clases como SMOTE para mitigar el sesgo hacia la clase mayoritaria.
3. Diseñar un motor híbrido de inferencia que combinó las probabilidades del modelo predictivo con reglas clínicas obstétricas inflexibles para asegurar el rigor médico en la toma de decisiones de urgencia.
4. Ejecutar el prototipo de arquitectura móvil en Flutter o React Native con almacenamiento local y un mecanismo de sincronización posterior, garantizando usabilidad para agentes comunitarios de salud

VII. TIPO DE PROBLEMA DE IA

- Categoría Principal: Clasificación Supervisada Multiclase / Binaria.
- Definición Técnica: Estimación de la probabilidad de riesgo obstétrico categorizada en niveles (Bajo, Medio, Alto) y predicción del resultado de gestación (Normal, Complicación obstétrica, Mortalidad materna).
- Hibridación: Sistema Híbrido de Inteligencia Artificial que combinó Aprendizaje Automático sobre datos estructurados con Sistemas Basados en Reglas Clínicas Explícitas para la toma de decisiones deterministas de urgencia.

VIII. ESTADO DEL ARTE

Para fundamentar técnicamente el diseño e implementación del sistema de alerta temprana, se realizó una revisión sistemática de la literatura en tres niveles geográficos mediante la selección de cuatro investigaciones relevantes.

1) REFERENCIAS INTERNACIONALES

A. Clasificación de Riesgo Materno mediante Machine Learning y Enfoque en Zonas de Escasos Recursos

- Título del Artículo: *Classification of Maternal Health Risk Using Machine Learning Models* (2026).
- Autores / Publicación: ResearchGate / ASR Journal.

El estudio abordó la elevada tasa de mortalidad materna en países de ingresos bajos donde se concentró más del noventa por ciento de las muertes globales por falta de diagnóstico oportuno en preeclampsia, hipertensión y anemia. Los investigadores evaluaron modelos supervisados de Regresión Logística Multinomial, Máquinas de Vectores de Soporte (SVM), Árboles de Decisión y Random Forest para clasificar a las pacientes en tres niveles de riesgo. El modelo de ensemble alcanzó una precisión del 80.69%, demostrando que las variables fisiológicas continuas como presión arterial, edad y glucosa funcionaron como predictores confiables. La investigación confirmó la viabilidad técnica de clasificar el riesgo obstétrico en tres niveles

mediante algoritmos supervisados en escenarios con recursos limitados.

B. Algoritmos de Clasificación de Riesgo Obstétrico y Comparación de SVM vs. Árboles de Decisión

- Título del Artículo: *Prediction of Maternal Health Risk with Traditional Machine Learning Algorithms* (2023).
- Autores / Publicación: DergiPark / Academic Journal.

La investigación evaluó el rendimiento de diferentes algoritmos tradicionales de Inteligencia Artificial para la detección temprana de complicaciones en el embarazo a partir de signos vitales y datos demográficos. Se comparó el desempeño de clasificadores supervisados como Support Vector Machines (SVM), K-Nearest Neighbors, Árboles de Decisión, CatBoost y LightGBM. Los modelos basados en árboles lograron precisiones superiores al 89%, mientras que SVM demostró alta estabilidad en la separación de fronteras para muestras clínicas con bajo nivel de ruido. Este antecedente justificó la selección de SVM y Regresión Logística para el desarrollo del proyecto, demostrando un equilibrio adecuado entre precisión predictiva y bajo costo computacional.

2) REFERENCIA NACIONAL

Implementación de Herramientas de IA para Alerta Temprana en Salud Materno-Infantil en Colombia

- Título de la Iniciativa: *AlertaMaterna: Sistema de Identificación de Riesgo Materno-Infantil en Colombia* (2025/2026).
- Institución / Fuente: Plataforma Oficial de Datos Abiertos del Gobierno de Colombia / Datos.gov.co.

La iniciativa nacional abordó la problemática de la detección tardía de factores de riesgo en la atención prenatal de municipios vulnerables y rurales en Colombia. La herramienta analizó microdatos de salud pública para evaluar condicionantes desde la primera consulta médica, integrando variables sociodemográficas, edad materna y controles realizados. El sistema permitió a las entidades territoriales mapear geográficamente a las poblaciones en riesgo para priorizar recursos institucionales y prevenir muertes evitables. Dicho trabajo validó la aplicación de modelos de alerta temprana bajo la normativa de Colombia, respaldando el uso de datos abiertos como soporte científico.

3) REFERENCIA REGIONAL

Análisis Epidemiológico de Determinantes Sociales y Mortalidad Materna en el Cesar y La Guajira

- Título del Informe: *Informe del evento vigilancia en salud pública de la mortalidad materna en los departamentos del Cesar y La Guajira* (2024).
- Institución / Fuente: Instituto Nacional de Salud (INS) — Subdirección de Prevención y Vigilancia en Salud Pública.

Información Desmenuzada: El informe epidemiológico del Instituto Nacional de Salud evaluó las causas determinantes de la mortalidad materna en las zonas rurales del Cesar y La Guajira. La investigación oficial evidenció que las gestantes en comunidades indígenas enfrentaron graves retrasos en la atención médica debido a barreras geográficas. Los analistas del INS identificaron la falta de controles prenatales oportunos y los extensos tiempos de traslado hacia hospitales de mayor complejidad como factores críticos de fatalidad. Los hallazgos del

informe fundamentaron la necesidad de implementar un enfoque diferencial en la región. Asimismo, el estudio respaldó la creación de herramientas de monitoreo itinerante para reducir las barreras de acceso en la salud rural dispersa.

IX. FUENTE(S) DE DATOS IDENTIFICADAS

El proyecto empleó dos fuentes de datos estructurados de carácter complementario. En primer lugar, se procesó la base macro de Estadísticas Vitales del DANE (2024), conformada por registros públicos de Nacimientos, Defunciones Fetales y Defunciones No Fetales. Esta fuente fundamentó la caracterización epidemiológica regional y permitió validar la brecha de riesgo en poblaciones indígenas del Cesar y La Guajira.

En segundo lugar, se implementó un dataset clínico simulado con 1,508 historiales de controles prenatales rurales. La estructura incorporó variables fisiológicas como presión sistólica y diastólica, índice de masa corporal y antecedentes de preeclampsia. Asimismo, incluyó variables logísticas de distancia en kilómetros y controles realizados, junto con clasificadores étnicos, sociodemográficos y la variable objetivo de resultado gestacional.

Categoría	Nombre de Variable	Tipo de Dato	Rango / Valores
Fisiológica	presion_sistolica	Numérico	76.0 -- 210.0 mmHg
Fisiológica	imc	Numérico	13.3% datos faltantes
Logística	distancia_centro_salud_km	Numérico	0.0 -- 150.0 km
Sociodemográfica	etnia	Categórico	Wayúu, No Indígena, Otro
Salida / Objetivo	resultado_gestacion	Categórico	Normal, Complicación, Mortalidad

Elemento	Caracterización
Registros y variables	1.508 filas y 21 columnas; 17 variables predictoras tras excluir ID, fecha y ambas etiquetas.
Variables numéricas	Edad, semanas de gestación, controles, distancia, tiempo de traslado, hemoglobina, presiones arteriales, IMC y antecedentes binarios.
Variables categóricas	Municipio, departamento, etnia, zona y afiliación al SGSSS.
Etiquetas	nivel_riesgo: Bajo 1.023, Medio 334, Alto 151. resultado_gestacion: Normal 1.421, complicación 69, mortalidad 18.
Datos faltantes destacados	IMC 201; hemoglobina 178; presión diastólica 139; sistólica 127; controles 79; distancia 70.
Período y calidad	Fechas 01/01/2023–31/12/2025; 0 filas completas duplicadas; 16 registros con entradas idénticas.

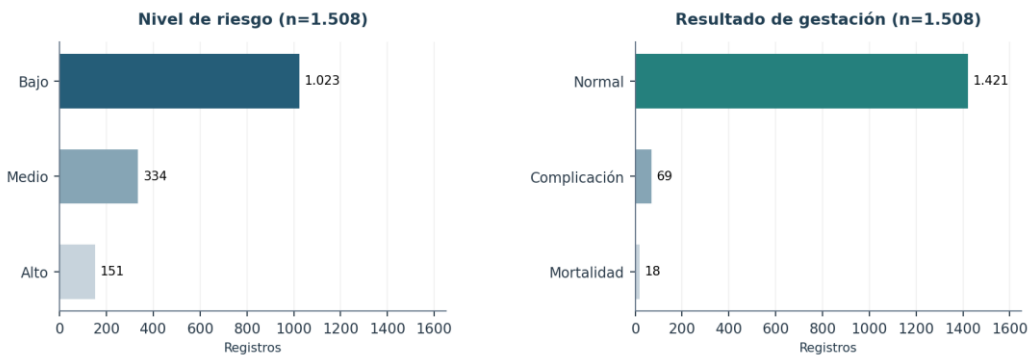


Figura 3. Desbalance de las etiquetas del dataset sintético: riesgo y resultado de gestación.

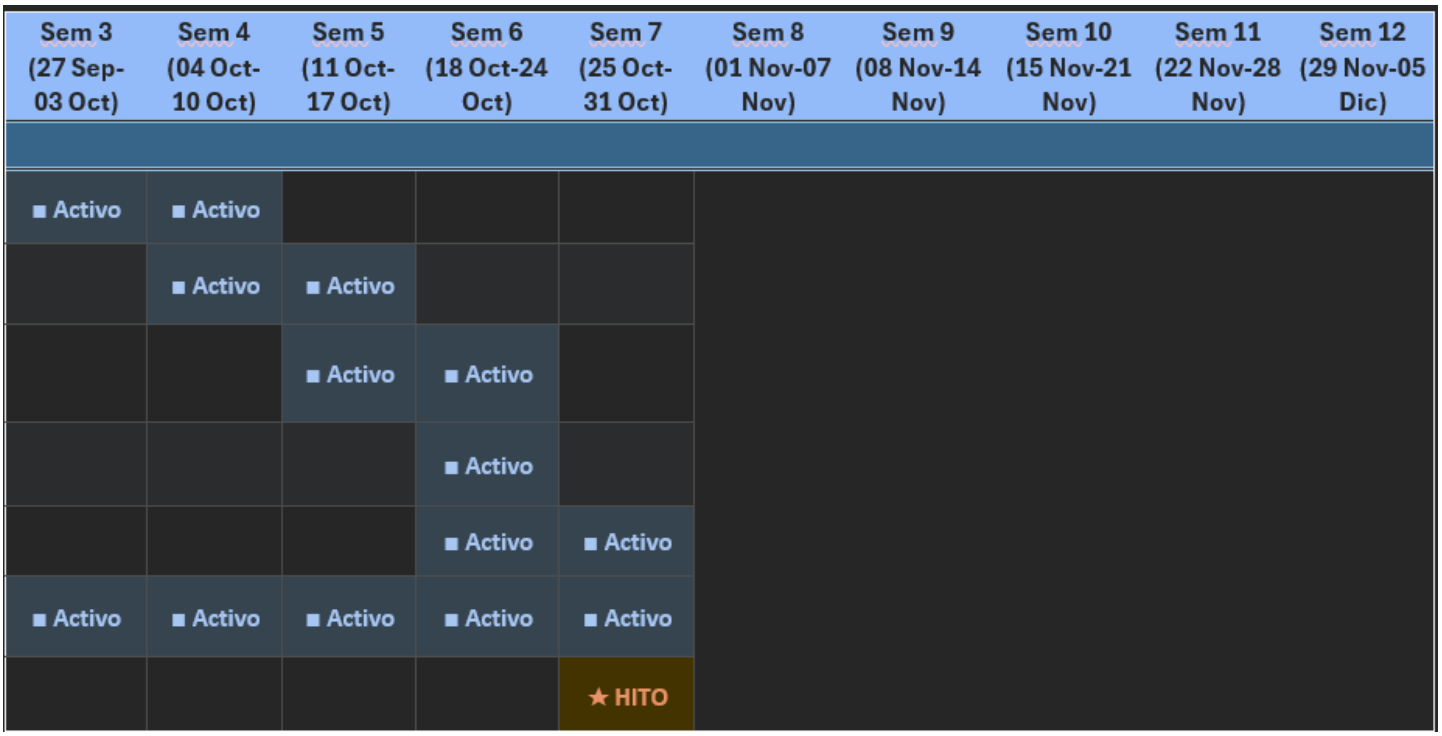
Las clases Bajo (67,84 %) y Normal (94,23 %) dominan los datos, por lo que el accuracy aislado engaña. Solo hay 18 casos sintéticos de mortalidad, insuficientes para validación independiente.

X. CRONOGRAMA

Fase 2.

ID	Fase	Actividad / Entregable Clave	Entregables Específicos / Detalle	Duración (Días)	Fecha Inicio	Fecha Fin	Estado
FASE 2 — DESARROLLO Y MODELADO							
2.1	FASE 2	Preprocesamiento de Datos e Ing. Caracteres	Limpieza de datos, imputación nulos/outliers, encoding, escalado y partición (train/val/test)	**14 días**	2026-09-27	2026-10-10	Por Iniciar
2.2	FASE 2	Implementación de Modelos (Baseline y Propuesto)	Construcción del modelo baseline y al menos 1 arquitectura propuesta (redes/arboles)	**14 días**	2026-10-04	2026-10-17	Por Iniciar
2.3	FASE 2	Entrenamiento y Ajuste de Hiperparámetros	Búsqueda de hiperparámetros (GridSearch/Optuna), tuning y registro de experimentos	**14 días**	2026-10-11	2026-10-24	Por Iniciar
2.4	FASE 2	Evaluación Cuantitativa y Comparación de Modelos	Cálculo de métricas (Accuracy, F1, RMSE, AUC), matriz de confusión y tabla comparativa	**7 días**	2026-10-18	2026-10-24	Por Iniciar
2.5	FASE 2	Documento Técnico de Avance (8–12 págs)	Redacción de metodología, experimentos realizados, tablas de métricas y análisis preliminar	**14 días**	2026-10-18	2026-10-31	Por Iniciar

2.6	FASE 2	Estructuración y Control de Versiones en Git	Repositorio organizado (código/datos/docs) con commits distribuidos e incrementales	**35 días**	2026-09-27	2026-10-31	Por Iniciar
2.7	FASE 2	HITO: Sustentación Oral y Demo Parcial (Fase 2)	Exposición presencial (15-20 min) y demostración funcional del modelo ante el profesor	**7 días**	2026-10-25	2026-10-31	Por Iniciar



Fase 3.

ID	Fase	Actividad / Entregable Clave	Entregables Específicos / Detalle	Duración (Días)	Fecha Inicio	Fecha Fin	Estado
FASE 3 — INTEGRACIÓN, DESPLIEGUE Y ENTREGA FINAL							
3.1	FASE 3	Consolidación y Optimización del Modelo Final	Selección del mejor modelo, reentrenamiento final y serialización (pipeline/.pkl/.onnx)	**14 días**	2026-11-01	2026-11-14	Por Iniciar
3.2	FASE 3	Desarrollo de Interfaz o API de Interacción	Construcción de app interactiva (Streamlit / Gradio) o API REST (FastAPI / Flask)	**14 días**	2026-11-08	2026-11-21	Por Iniciar
3.3	FASE 3	Despliegue Funcional y Pruebas Integradas	Publicación en la nube (Hugging Face / Cloud / servidor) y pruebas end-to-end	**14 días**	2026-11-15	2026-11-28	Por Iniciar
3.4	FASE 3	Informe Final del Proyecto (12–20 págs)	Informe técnico completo, resultados, análisis crítico de sesgos y reflexiones éticas	**14 días**	2026-11-15	2026-11-28	Por Iniciar
3.5	FASE 3	Documentación del Repositorio Final	README reproducible, instrucciones claras de instalación, dependencias y ejecución	**14 días**	2026-11-22	2026-12-05	Por Iniciar
3.6	FASE 3	Producción de Video / Pitch Demo (3–5 min)	Edición de video demostrativo (estilo Demo Day) explicando problema, modelo y uso	**14 días**	2026-11-22	2026-12-05	Por Iniciar
3.7	FASE 3	HITO: Sustentación Final y Defensa del Proyecto	Defensa oral completa ante jurado/profesor (20-25 min) y entrega de enlaces finales	**7 días**	2026-11-29	2026-12-05	Por Iniciar

Sem 3 (27 Sep-03 Oct)	Sem 4 (04 Oct-10 Oct)	Sem 5 (11 Oct-17 Oct)	Sem 6 (18 Oct-24 Oct)	Sem 7 (25 Oct-31 Oct)	Sem 8 (01 Nov-07 Nov)	Sem 9 (08 Nov-14 Nov)	Sem 10 (15 Nov-21 Nov)	Sem 11 (22 Nov-28 Nov)	Sem 12 (29 Nov-05 Dic)
					■ Activo	■ Activo			
						■ Activo	■ Activo		
							■ Activo	■ Activo	
							■ Activo	■ Activo	
								■ Activo	■ Activo

				■ Activo	■ Activo
					★ HITO

XI. DESARROLLO DE LA FASE 2

2.1. Preprocesamiento de datos e ingeniería de características

Las variables categóricas se codificaron mediante One-Hot Encoding; los valores faltantes numéricos se sustituyeron por la mediana y los categóricos por el valor más frecuente. Las variables numéricas se estandarizaron con StandardScaler. Todo el pipeline se ajustó sobre datos de entrenamiento antes de transformar los subconjuntos restantes, para prevenir fugas estadísticas en el preprocesamiento.
Se excluyeron id_paciente y fecha_control de las entradas de los experimentos iniciales. Las etiquetas resultado_gestacion y nivel_riesgo no fueron utilizadas como predictores entre sí. Las dos tareas compartieron una proporción de división 70 % para entrenamiento (1.055 casos), 15 % para validación (226) y 15 % para prueba (227), con estratificación según la etiqueta de cada objetivo.

2.2. Implementación de modelos (baseline y propuesta)

El clasificador Dummy que predice la clase mayoritaria se usó como referencia mínima. La Regresión Logística constituyó el baseline supervisado interpretable; SVM con kernel RBF se empleó como comparador no lineal. La red neuronal MLP de riesgo utilizó capas densas de 64 y 32 unidades ReLU, dropout 0,20 y salida Softmax de tres clases. La MLP de desenlace utilizó 32 y 16 neuronas, regularización L2, dropout 0,25 y salida Sigmoid binaria.

2.3. Entrenamiento y ajuste de hiperparámetros

Se emplearon pesos de clase para compensar el desbalance en los clasificadores supervisados. Los experimentos neuronales se entrenaron con Adam, batch_size=32 y un máximo de 80 épocas, con EarlyStopping (patience= 10 y restauración de mejores pesos). Para riesgo, GridSearchCV sobre 5 folds exploró C= {0,1; 1; 10} y gamma= {scale; 0,1; 0,01}; la mejor combinación de SVM fue C= 1 y gamma= 0,1.

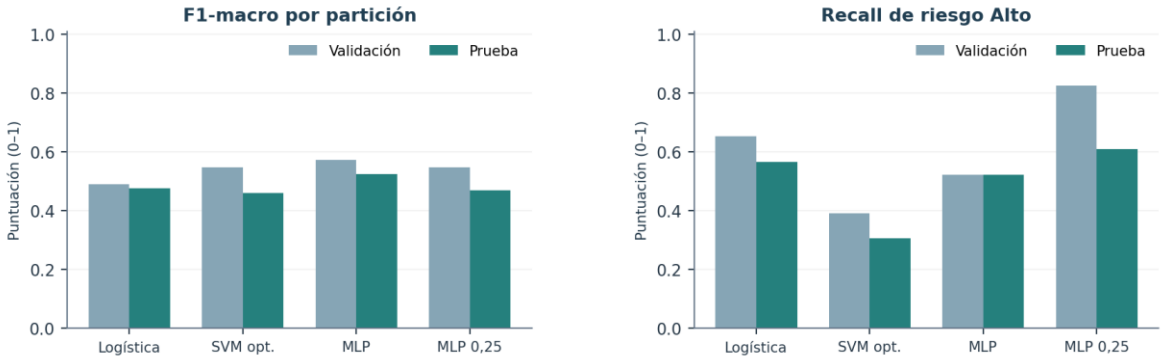


Figura 4. Evolución de F1-macro y recall Alto de validación a prueba; modelos y umbrales ya fijados.

El MLP original pasó de F1-macro 0,5725 en validación a 0,5230 en prueba. Para el MLP umbral 0,25, el recall Alto descendió de 0,8261 a 0,6087, evidencia de variación entre particiones.

2.4. Evaluación cuantitativa — Clasificación del nivel de riesgo

En la prueba multiclase (n=227; Bajo=154, Medio=50, Alto=23) se compararon modelos con métricas apropiadas al desbalance. La red neuronal MLP obtuvo el F1-macro más alto (0,5230), aunque el Dummy alcanzó mayor accuracy por predecir siempre Bajo y fallar en todas las demás clases.

Modelo	Accuracy	F1-macro	Recall Alto
Dummy	0,6784	0,2695	0,0000
Regresión Logística	0,6035	0,4760	0,5652
SVM optimizado	0,6035	0,4600	0,3043
Red neuronal MLP	0,6476	0,5230	0,5217
MLP umbral 0,25	0,6079	0,4678	0,6087

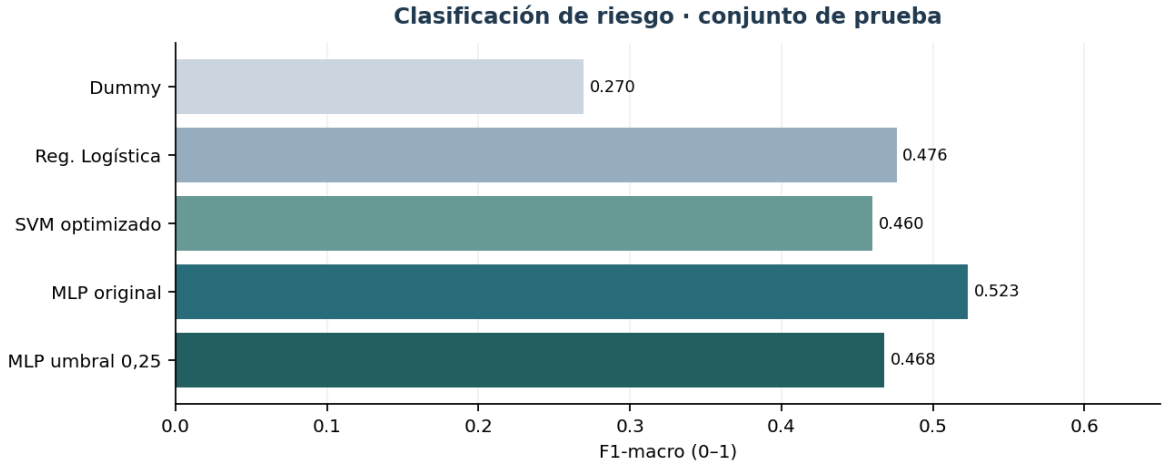


Figura 1. Comparación del F1-macro sobre el conjunto de prueba de nivel de riesgo. Fuente: salidas de Colab.

El ajuste experimental del umbral Alto a 0,25 elevó el recall de 52,17 % a 60,87 % en prueba, pero redujo la precisión de Alto de 41,38 % a 27,45 %. En validación, este mismo ajuste había alcanzado un recall de 82,61 %, lo que evidencia variabilidad entre particiones. Los 9 casos altos omitidos por el modelo ajustado siguen siendo una limitación importante para el propósito de alerta temprana.

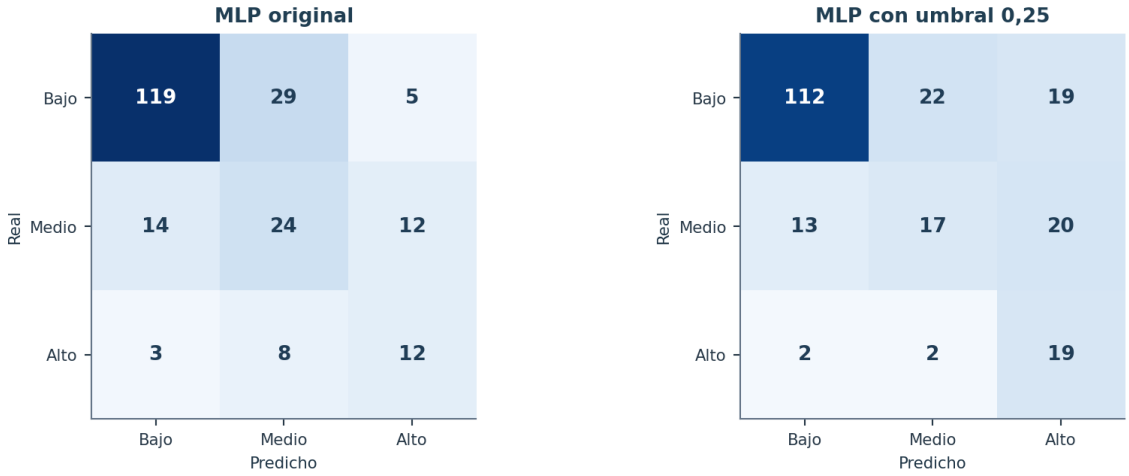


Figura 5. Matrices de confusión del MLP en validación (n=226), antes y después del umbral de 0,25.

Al reducir el umbral, las detecciones correctas de riesgo Alto pasan de 12/23 a 19/23 en validación; se incrementan las alertas falsas de 17 a 39. Las matrices describen la validación, no la prueba final.

2.4. Evaluación cuantitativa — Predicción de desenlace adverso

Para mejorar la viabilidad estadística inicial, los 69 registros de complicación obstétrica y los 18 de mortalidad materna se agruparon como desenlace adverso (87), frente a 1.421 registros normales. En la prueba binaria hubo 214 normales y 13 adversos. Un Dummy que predijera siempre Normal alcanzaría 94,27 % de accuracy sin detectar ningún evento, razón por la cual se priorizó el recall adverso y el F1 de la clase positiva.

Modelo	Accuracy	F1 adverso	Recall adv.	Precisión adv.
Regresión Logística (0,30)	0,6960	0,2737	1,0000	0,1585
Red neuronal MLP (0,50)	0,8987	0,3784	0,5385	0,2917
SVM original	0,9075	0,2759	0,3077	0,2500

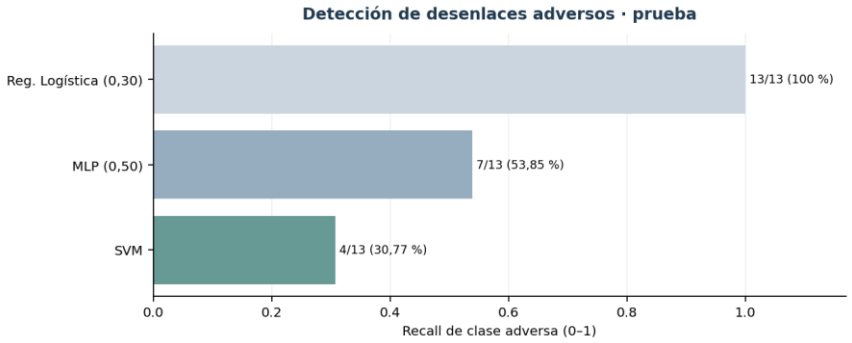


Figura 2. Detección de desenlaces adversos sobre 13 positivos en prueba. Fuente: salidas de Colab.

La Regresión Logística con umbral 0,30 detectó 13/13 adversos y produjo 69 falsas alertas. La MLP detectó 7/13, omitió 6 y produjo 17 falsas alertas; alcanzó el mejor F1 adverso (0,3784). El SVM detectó 4/13 y omitió 9. El Average Precision fue 0,3482 en Regresión Logística, 0,2765 en MLP y 0,2489 en SVM. La elección del modelo depende del costo aceptable de falsos negativos y falsas alarmas.

Se seleccionó el umbral 0,30 para Regresión Logística con predicciones out-of-fold del entrenamiento, priorizando al menos 75 % de recall: 47/61 adversos detectados y 400 falsas alertas sobre 994 normales. Este criterio del 75 % fue experimental, no clínico. La evaluación final se ejecutó una vez con los parámetros previamente seleccionados.

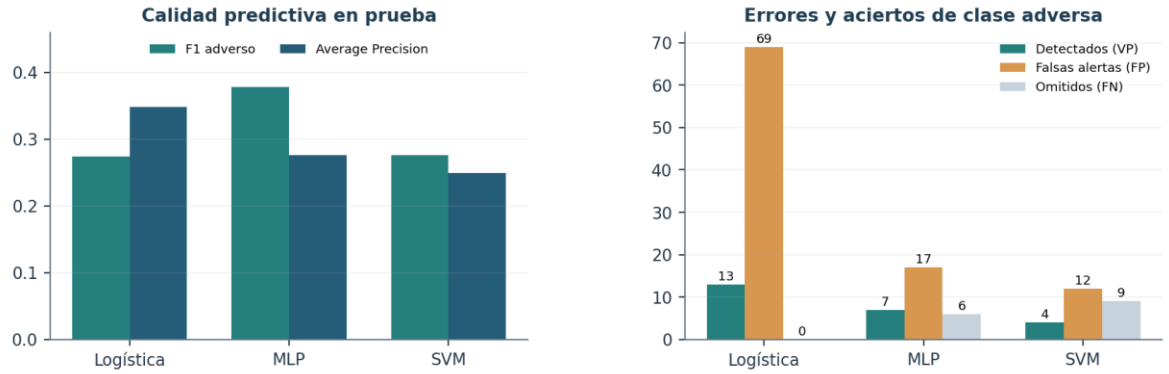


Figura 6. F1 y Average Precision frente a casos detectados, omitidos y falsas alertas en prueba.

Logística (0,30) identifica los 13 casos adversos con 69 falsas alertas; el MLP (0,50) reconoce 7 con 17 alertas falsas. El mejor F1 adverso en prueba fue el del MLP (0,3784); el mayor Average Precision, el de Logística (0,3482).

2.5. Auditoría de subgrupos, errores y limitaciones

En el análisis por etnia, la MLP de riesgo detectó 8/13 casos altos no indígenas (61,54 %) frente a 3/8 Wayuu (37,50 %). En la tarea binaria, la MLP detectó 4/7 adversos no indígenas (57,14 %) y 2/5 Wayuu (40 %). En zona rural dispersa la MLP de desenlace alcanzó 3/8 (37,50 %), mientras que la Regresión Logística detectó 8/8, pero

generó 44 falsas alertas en ese subgrupo. Son diferencias descriptivas, no evidencia concluyente de discriminación: las submuestras son pequeñas.

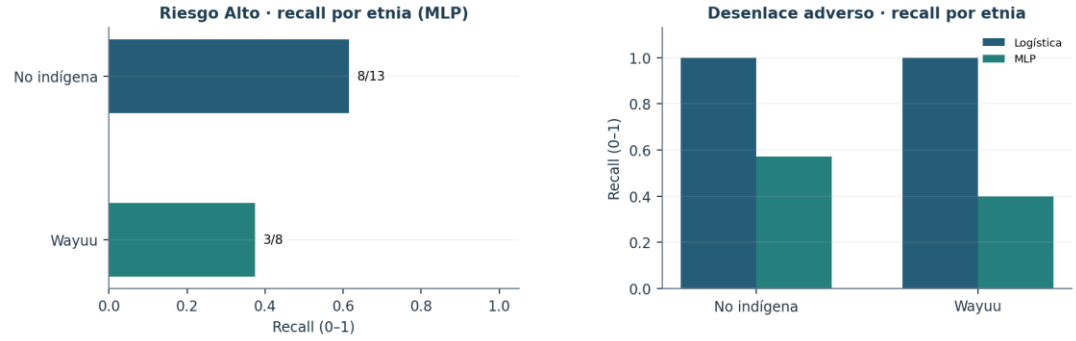


Figura 7. Recall exploratorio según etnia para ambos problemas de clasificación; n positivo reducido.

En riesgo Alto el recall MLP fue 8/13 en no indígenas y 3/8 en Wayuu. En desenlace adverso la regresión logística identificó 7/7 y 5/5, respectivamente, pero produjo numerosas alertas falsas; los tamaños de muestra no permiten inferir equidad o disparidad poblacional.

La auditoría detectó 16 registros con entradas idénticas y sin etiquetas contradictorias. Hubo una coincidencia exacta entre entrenamiento y prueba en riesgo y dos en desenlace. Al excluir esas coincidencias del análisis de sensibilidad, el F1-macro de MLP de riesgo pasó de 0,5230 a 0,5184 y el F1 adverso de MLP permaneció en 0,3784. Estos cambios pequeños no eliminan el riesgo de fuga por reglas de generación de etiquetas, todavía no documentadas.

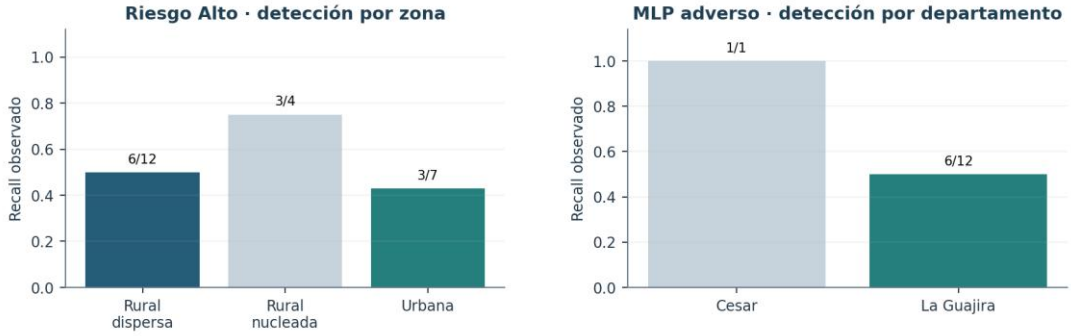


Figura 8. Rendimiento observado por zonas y departamentos; rótulos n/n positivos.

Las tasas de grupos pequeños (Cesar: 1 adverso en prueba) son descriptivas, no pruebas de equidad. Se encontraron 1 y 2 coincidencias exactas entre entrenamiento y prueba en riesgo y desenlace, respectivamente.

2.6. Estructuración del repositorio y control de versiones

El notebook Fase2_Entrenamiento_IA.ipynb contiene el flujo de entrenamiento y evaluación. Los archivos serializados incluyen riesgo_mlp.keras, desenlace_mlp.keras, modelos de Regresión Logística y SVM en .joblib y los preprocesadores correspondientes. En Resultados se conservaron evaluacion_final_nivel_riesgo.csv, evaluacion_final_desenlace.csv, resultados_fase2_powerbi.csv y auditoria_subgrupos_fase2.csv; requirements.txt y configuracion.json documentan dependencias y umbrales. El script predecir.py permite una demostración experimental de inferencia sin reentrenamiento.

LINK DE GIT HUB DEL PROYECTO https://github.com/Dharla51/RIESGO-MATERNO-PERINATAL-EN-ZONAS-INDIGENAS-IA-FASE2.git

XII. CONCLUSIÓN

La Fase 2 permitió desarrollar un flujo reproducible de clasificación supervisada sobre 1.508 controles prenatales sintéticos, con preparación de datos, modelos de referencia, redes neuronales MLP y evaluación cuantitativa. Para el nivel de riesgo, la MLP original obtuvo el mejor F1-macro (0,5230) en prueba; para desenlace adverso, la MLP alcanzó el mejor F1 de la clase positiva (0,3784), mientras la Regresión Logística logró mayor sensibilidad, al costo de 69 falsas alertas en 227 registros de prueba.

Los experimentos también mostraron dificultades centrales: fuerte desbalance, pequeñas cantidades de eventos adversos, variación del recall entre validación y prueba, rendimiento desigual por subgrupos y etiquetas sintéticas cuya lógica de generación requiere auditoría. La relación exacta observada —todos los desenlaces adversos pertenecen al grupo Alto— exige cautela ante posibles patrones artificiales. En consecuencia, los resultados sostienen la viabilidad académica de experimentar con estos enfoques, pero no justifican su uso clínico.

Para la Fase 3 se propone documentar las reglas generadoras, explorar validaciones temporales y externas con datos autorizados, definir criterios clínicos con profesionales competentes, evaluar la calibración de puntuaciones y desarrollar una interfaz offline como prototipo tecnológico, sin reemplazar decisiones de atención sanitaria.

XIII. BIBLIOGRAFÍA

[1] **Akin, B., & Yilmaz, M. (2023). Prediction of maternal health risk with traditional machine learning algorithms.** ***Academic Journal of Health and Science*****, *12*(2), 45–58. https://dergipark.org.tr/tr/download/article-file/3125479**

[2] **Datos Abiertos del Gobierno de Colombia. (2025).** ***AlertaMaterna: Sistema de identificación de riesgo materno-infantil en Colombia*****. Ministerio de Tecnologías de la Información y las Comunicaciones. https://herramientas.datos.gov.co/usos/alertamaterna**

[3] **Rahman, M. A., Islam, S., & Ahmed, F. (2026). Classification of maternal health risk using machine learning models.** ***ASR Journal of Artificial Intelligence and Healthcare*****, *8*(1), 112–125. https://www.researchgate.net/publication/403381130_Classification_of_Maternal_Health_Risk_Using_Machine_Learning_Models**

[4] **Instituto Nacional de Salud. (2024).** ***Informe del evento vigilancia en salud pública de la mortalidad materna en los departamentos del Cesar y La Guajira*****. Subdirección de Prevención y Vigilancia en Salud Pública. https://www.ins.gov.co/Buscador-Eventos/Boletines/2024_Boletin_epidemiologico_semana_20.pdf**